

Modelos de lenguaje pequeños en local: qué se pierde y qué se gana

Luciano Sánchez

29 de septiembre de 2026 · Centro Niemeyer, Avilés

Informes y salidas de la demostración

Repositorio público

- `informes/`: el informe de alta sintético
- `resultados/`: los textos y JSON de los cuatro modelos
- `prompts/`: las instrucciones de cada tarea

Las salidas se identifican por tarea y modelo: 01 a 05, con las etiquetas 3B, 8B, 27B y Opus5.



[github.com/lucianosanchez/
demoSLM-IASalud](https://github.com/lucianosanchez/demoSLM-IASalud)

Los informes usados y las respuestas de todos los modelos empleados en esta demostración ya están precalculados y pueden consultarse desde el QR. Todos los informes son ficticios.

El caso clínico que vamos a evaluar

Manuel Fernández Argüelles, 67 años, 58 kg. Informe sintético con errores deliberados.

Por qué ingresa

Ingresa en Medicina Interna del HUCA del 12 al 21/02/2025 por disnea, edemas y síntomas urinarios.

Insuficiencia cardíaca descompensada (FEVI 55 %), EPOC agudizada e infección urinaria por *E. coli* BLEE, resistente a varios antibióticos.

Diabetes con daño renal y retiniano, enfermedad renal en estadio 4, fibrilación auricular e hipertensión. Exfumador con oxígeno. Crohn en remisión y hernia operada.

Se realizarán **cinco tareas con IA**: (1) anonimizar, (2) extraer información, (3) explicar el alta, (4) asociar códigos CIE y (5) revisar el tratamiento.

Evolución y alta

Recibe oxígeno, diuréticos, corticoide y meropenem durante siete días. Sufre deterioro renal transitorio. Se suspende la metformina.

El alta incluye **10 diagnósticos, 9 fármacos y oxígeno**, seis recomendaciones y citas de enfermería, Medicina Interna y Nefrología.

Pautas: avisar si gana **2 kg o más en 3 días**, menos de **2 g de sal/día**, hasta **1,5 L/día**, oxígeno **16 h/día** y analítica en **7-10 días**.

Incoherencias del informe

Prescripción al alta

Datos con los que habrá que cuestionarla

Amoxicilina-clavulánico

875/125 mg cada 8 h, 5 días

Alergia a betalactámicos tras amoxicilina, cultivo **resistente** a este antibiótico y **7 días de meropenem** ya administrados.

Metformina

850 mg cada 12 h

Se suspendió por deterioro renal y reaparece con **FGe 22 mL/min/1,73 m²**. El umbral de contraindicación, **menor de 30**, no figura en el informe.

Apixabán

5 mg cada 12 h

58 kg (≤ 60) y creatinina 1,9 ($\geq 1,5$ mg/dL): dos criterios de reducción a **2,5 mg cada 12 h**. No necesita cumplir el tercero, edad ≥ 80 años.

Falsas alarmas: bisoprolol con EPOC, oxígeno a 2 L/min, furosemida tras mejorar el riñón, insulina de 22 a 26 U y atorvastatina 40 mg.

El antibiótico debe conservarse al transformar el documento y cuestionarse en la revisión clínica. Veremos si cada modelo respeta el encargo, si pierde información o si inventa contenido.

Tareas que deseamos automatizar

Tarea	Información necesaria	Resultado exigido
Anonimización	Nombres, fechas y lugares del informe	Sustituirlos sin borrar clínica.
Extracción	Edad, alergias, medicación y dosis	Conservar datos y cifras.
Reescritura	Tratamiento y recomendaciones	Simplificar sin omitir ni cambiar pautas.
Codificación CIE	Diagnósticos + tabla oficial y normas	Códigos completos y secuencia correcta.
Revisión clínica	Datos del caso + criterios clínicos	Señalar errores y justificar cada alerta.

Las tareas 1–3 trabajan con información del documento. Las 4–5 exigen además códigos o criterios que el modelo debe aportar.

Dificultades relativas al contenido

Tarea	Particularidades del informe que habrá que respetar
Anonimización	Nombres e identificadores, teléfonos, centros y topónimos. HUCA se repite. Hay fechas como «enero de 2024». Deben conservarse los términos clínicos como Crohn, Charlson y Homans pero ningún apellido de un paciente, nombre de una calle, etc.
Extracción	Nace el 14/03/1957 e ingresa el 12/02/2025: 67 años . Insulina: 100 U/mL de concentración, 22 U antes y 26 U a las 22:00 al alta .
Selección temporal	FGe: 25 basal, 22 al alta (mL/min/1,73 m ²). Creatinina: 2,4 en el día +4, 1,9 mg/dL al alta . Prednisona y meropenem se administran durante el ingreso.
Reescritura	Conservar dosis, horarios, alarmas y citas. Explicar BLEE. Vacuna antigripal anual y antineumocócica sin periodicidad indicada.
Codificación	FEVI preservada, estadio renal 4 e insuficiencia respiratoria crónica agudizada hipercápnica. Códigos completos y secuenciación.

Se comprobará si la IA produce respuestas legibles y correctas, y conserva significado y cifras.

Dificultades relativas a la gestión de los datos

El tratamiento empieza al introducir el documento.

Datos de salud expuestos

Diagnósticos, medicación e historia clínica son datos especialmente protegidos. Su tratamiento necesita base jurídica y una habilitación del art. 9 del RGPD.

Copias y usos posteriores

El texto puede quedar en historiales o registros. La conservación y el posible uso para entrenamiento dependen del servicio, el contrato y la configuración.

Acceso de terceros

Hay que conocer quién procesa los datos, sus subencargados y dónde lo hace. Las transferencias fuera del EEE requieren garantías cuando correspondan.

Reidentificación y fugas

Quitar el nombre puede ser insuficiente: fechas, centros y enfermedades poco frecuentes permiten identificar. La respuesta también puede revelar datos personales.

Por eso usamos informes ficticios y evaluamos la anonimización antes de trabajar con datos reales.

Fuente: RGPD, arts. 5, 6, 9, 28, 32 y 44-49; considerando 26.

Calendario europeo: obligaciones vigentes

Fecha	Obligaciones y plazos del Reglamento de IA
1 agosto 2024	Entrada en vigor del Reglamento (UE) 2024/1689.
2 febrero 2025	Prácticas prohibidas iniciales y alfabetización en IA.
2 agosto 2025	Gobernanza y obligaciones para modelos de uso general.
27 julio 2026	Entra en vigor la reforma 2026/1744: cambia los plazos de alto riesgo.
2 agosto 2026	Aplicación general, potestades de ejecución y reglas de transparencia.
2 diciembre 2027	Sistemas de alto riesgo del anexo III (art. 6.2).
2 agosto 2028	Sistemas de alto riesgo vinculados a productos del anexo I (art. 6.1).

Los plazos de 2027 y 2028 no aplazan el RGPD. Si un servicio externo va a recibir informes, sus garantías deben estar resueltas antes del primer envío.

Mantener el informe en equipos propios evita incorporar ese tratamiento por terceros a cada pequeña tarea.

Fuente: Comisión Europea, actualización de 03/08/2026; Reglamento (UE) 2026/1744; RGPD. Consulta: 10/09/2026.

Decreto 98/2025: por qué usar modelos locales

Exigencia	Gestión de un servicio externo	Qué facilita el procesamiento local
Privacidad art. 3.f + RGPD	Contrato de encargado, subencargados, ubicación y transferencias cuando procedan.	El informe no se comunica a un proveedor de IA.
Verificación y contratación arts. 12 y 12.3	Evaluar el servicio y disponer de pruebas y conformidad según su ámbito; controlar sus cambios.	Fijar la versión del modelo y repetir las pruebas sobre ella.
Trazabilidad y registro arts. 3.g/i y 17.3.a*	Obtener documentación y registros suficientes del servicio.	Conservar instrucciones, salidas, versión y parámetros en la organización.
Revisión y retirada arts. 3.h** y 30	Garantizar revisión humana y poder interrumpir el servicio.	Revisar resultados y desactivar el sistema bajo control propio.

Si una tarea pequeña no dispone de recursos para contratar y supervisar un servicio externo, procesarla en local evita añadir esa gestión del proveedor.

*En el espacio de pruebas. **Decisiones administrativas automatizadas. Decreto aplicable a la Administración del Principado y su sector público.

Fuente: BOPA, Decreto 98/2025; RGPD, arts. 28 y 44-49.

¿Cuánta RAM necesitan los equipos?

A 4 bits: aproximadamente 0,6 GB por cada mil millones de parámetros.

Modelo	8B	27B	70B
Archivo a 4 bits	4,8 GB	16,2 GB	42 GB
Espacio para 8.192 tokens*	0,9 GB	1,7 GB	2,8 GB
Total aproximado*	5,7 GB	17,9 GB	44,8 GB

El 27B de la demostración usa **8 bits y un archivo de 30 GB**. La memoria depende también de la precisión, no solo del número de parámetros.

*Hay que añadir margen para el programa y el sistema operativo. Documentos más largos y varias solicitudes simultáneas necesitan más espacio.

Fuente: `scripts/hardware.py`: Q4_K_M, 4,8 bits efectivos/parámetro; contexto de 8.192 tokens. Caché estimada según su aproximación de arquitectura.

Mucha RAM no garantiza una respuesta rápida

Cabe, pero puede ser lento

70B a 4 bits: unos 45 GB.

Un servidor con **512 GB de RAM** tiene capacidad de sobra.

Con 100 GB/s de memoria, el cálculo orientativo da **1–2 tok/s**: unos **8–17 minutos** para generar 1.000 tokens.

La RAM permite cargar el modelo. La GPU (tarjeta gráfica) puede acelerar la generación y atender más solicitudes. Hay que medir ambas necesidades por separado.

Fuente: escenario teórico de hardware.py; llama.cpp: ejecución paralela y agrupación de solicitudes.

Una persona o muchas

Con una sola solicitud importa cuánto tarda en terminar.

Con **200 solicitudes simultáneas** importan también la cola y la capacidad total.

Procesarlas en grupos permite compartir trabajo; requiere memoria y capacidad de cálculo adicionales.

Qué equipo permite cada expectativa de uso

Escenario de equipo	Memoria	GB/s	Modelo	tok/s*	Expectativa de uso
Móvil / tableta	6 GB	50	3B	10–15	Textos breves y plantillas.
Portátil sin GPU	32 GB	80	8B	7–11	Extracción de informes; admite espera.
Apple Silicon	48 GB	300	27B	8–13	Reescritura individual; vigilar el razonamiento largo.
Servidor sin GPU	512 GB	100	70B	1–2	Procesos nocturnos; poca respuesta interactiva.
Servidor con 1 GPU	48 GB	1.000	32B	24–38	Servicio para pocos usuarios.
Servidor multi-GPU	160 GB	6.700	120B	44–71	Servicio compartido; agrupar solicitudes y gestionar colas.

512 GB de RAM permiten cargar el 70B, pero no compensan una memoria lenta. La GPU aporta velocidad, no acierto clínico.

*Estimaciones Q4_K_M y contexto de 8.192 tokens: 50–80 % de GB/s dividido por memoria del modelo y contexto. GB/s es el ancho de banda supuesto. No son medidas ni garantías por usuario.

Fuente: scripts/hardware.py. RAM en CPU, memoria de GPU o memoria unificada según plataforma.

Los modelos que hemos probado en la demo

Etiqueta	Modelo	Precisión	Archivo	Generación
3B	qwen3-4b-instruct-2507	4 bits	2,4 GB	80 tok/s
8B	qwen3-8b	4 bits	5,0 GB	60 tok/s
27B	qwen3.8-27b	8 bits	30 GB	22 tok/s
Opus 5	Referencia externa	—	—	—

- **B:** miles de millones de parámetros, los valores aprendidos del modelo. La etiqueta 3B corresponde aquí a un modelo de 4B.
- **4/8 bits:** precisión con la que se guardan esos valores. Reducirla se llama cuantización y ahorra memoria.
- **Token:** fragmento de texto; tok/s mide la velocidad de generación, incluido el razonamiento previo a la respuesta.

Opus recibió el informe ficticio; no tiene tiempos locales comparables. Cambian tamaño, versión, precisión y razonamiento: no se mide solo el efecto del tamaño.

La aplicación fija la tarea y registra el resultado

Informe + instrucciones fijas → modelo local → resultado

Encargo de extracción

«Extrae la medicación del alta con sus dosis y pautas. No añadas medicamentos.»

La aplicación envía estas instrucciones y el informe a **LM Studio**, que ejecuta el modelo en el equipo.

Registro de la ejecución

- Modelo y parámetros utilizados.
- Respuesta completa.
- Cantidad de texto generado y duración.
- Comparación con los resultados esperados.

Red desconectada. Las respuestas y los registros se conservan para comprobar cada resultado.

Fuente: scripts/ejecutar.py, scripts/evaluar.py y ficheros de resultados.

LAS CINCO TAREAS

Análisis de resultados

Ejecutamos cada una de las tareas y comprobamos si los modelos locales han sido capaces de solucionar el problema correctamente

Tarea 1. Anonimizar el documento

Encargo: sustituir los identificadores y conservar la información clínica.

Salida del 3B

confirmada por el Servicio de
Alergología del HUCA

Oxigenoterapia domiciliaria
desde enero de 2024

Permanecen el centro y la fecha.

Salida del 27B

confirmada por el Servicio de
Alergología del [CENTRO]

Oxigenoterapia domiciliaria
desde [FECHA]

Sustituye ambos identificadores y conserva la
información clínica.

Fuente: resultados/01-anonimizacion___3B.txt y 01-anonimizacion___27B.txt. Fragmentos literales.

Tarea 1. Identificadores eliminados: de 30 a 46

Informe de 1.379 palabras: 33 datos identificativos, con 46 apariciones que deben sustituirse.

30/46

3B

33/46

8B

46/46

27B

46/46

Opus 5

Identificadores eliminados

Los modelos pequeños dejan centros, topónimos, direcciones y algunas fechas.

Información clínica conservada

Los cuatro mantienen los 13 términos vigilados, incluidos Crohn, Charlson, Homans y Killip.

El 3B deja 16 apariciones; el 8B, 13. El 27B y Opus eliminan las 46 previstas en este informe.

Tarea 2. El 3B confunde concentración y dosis

Encargo: extraer la medicación del alta con sus dosis y pautas.

Informe original

Insulina glargina **100 U/mL**, **26 unidades** subcutáneas a las 22:00 h.

100

unidades · 3B

26

unidades · 8B

26

unidades · 27B

26

unidades · Opus 5

Campos devueltos por el 3B

```
"principio_activo": "insulina glargina",  
"dosis": "100",  
"unidad": "UI"
```

El 3B extrae 100 U de una concentración de 100 U/mL. La dosis prescrita era 26 U; los otros tres modelos la conservan.

Tarea 2. El 8B iguala la extracción de los mayores

Campo contrastado	3B	8B	27B	Opus 5
Edad al ingreso, esperada: 67 años	68	67	67	67
Datos individuales correctos	13/14	14/14	14/14	14/14
Pares medicamento–dosis coincidentes	8/9	9/9	9/9	9/9

Otro error del 3B

«2 inhalaciones al día» pasa a «2 veces al día». La frecuencia también necesita comprobación.

Se aceptan nombres equivalentes del mismo fármaco. El indicador automático F1 daba 0,889 en los cuatro modelos porque penalizaba esas variantes; el cotejo de medicamento y dosis distingue 8/9 de 9/9.

9/9 se refiere solo a medicamento y dosis. No incluye la conservación de horarios, unidades ni el número de inhalaciones.

Tarea 3. Cuatro respuestas al mismo encargo

Encargo: explicar el alta al paciente, conservando cifras y tratamiento.

Modelo	Qué hace con el antibiótico	Consecuencia documental
3B	Copia la pauta y añade «No debe tomar este medicamento en el futuro».	Añade una instrucción clínica.
8B	Omite la prescripción. Menciona amoxicilina solo en un comentario sobre alergia.	Falta un medicamento del alta.
27B	Copia 875/125 mg, cada 8 horas, durante 5 días, sin advertencias.	Conserva la pauta del original.
Opus 5	Copia la pauta y añade «No tome ese comprimido todavía».	Añade una instrucción clínica.

Fuente: lectura de resultados/o3-reescritura__*.txt. La conducta se refiere a esta prescripción.

Tarea 3. Una lectura fluida puede perder la pauta

8B: explicación sin dosis

«Insulina glargina: para regular el azúcar en sangre.»

En el apartado de medicación omite las dosis de los fármacos. Conserva la pauta del oxígeno.

El 8B también transforma «vacunación antigripal anual y vacunación antineumocócica» en «gripe y los neumococos cada año».

La facilidad de lectura y la fidelidad al documento se evalúan por separado. Un texto breve puede omitir o alterar instrucciones.

27B: dosis y horario

«Insulina glargina (insulina) 100 U/mL (unidades por mililitro), 26 unidades subcutáneas (bajo la piel) a las 22:00 h.»

Conserva la concentración, la cantidad administrada, la vía y la hora.

Tarea 3. Opus añade una decisión terapéutica

Contrato: simplificar el alta sin añadir consejos ni corregir el tratamiento.

«No tome ese comprimido todavía. Llame hoy a su centro de salud o al hospital y pregunte.»

Opus incumple el contrato

Detecta la alergia al antibiótico, pero incorpora una orden de no tomarlo. Si una alerta fuese errónea, podría inducir a omitir medicación necesaria.

El 27B respeta esta restricción

Conserva la prescripción al reescribir. Señala la incompatibilidad cuando se le encarga la revisión clínica, en la tarea 5.

El 27B es más fiel al encargo en este punto. La alerta debe revisarse por separado antes de entregar el alta al paciente.

Tarea 4. Confianza alta en un código incorrecto

Encargo: proponer códigos CIE-10-ES con su evidencia y nivel de confianza.

Fragmento de la salida del 8B

```
"codigo": "N18.5",  
"descripcion":  
  "Enfermedad renal crónica estadio 4,  
  de origen diabético",  
"confianza": "alta"
```

10/10

propuestas con confianza alta

2/16

códigos del patrón recuperados

El 8B dice «estadio 4» y propone N18.5, con confianza alta. La referencia de estadio 4 es N18.4.

Tarea 4. Códigos completos: 1, 2, 5 y 15 de 16

Coincidencia con el patrón propuesto	3B	8B	27B	Opus 5
Código completo	1/16	2/16	5/16	15/16
Categoría (tres primeros caracteres)	6/14	9/14	10/14	13/14
Diagnóstico principal	no	no	no	no

Qué falta en Opus

Omite Z99.81, dependencia de oxígeno. Propone I50.33 como principal y I13.0 como secundario, en orden distinto al patrón.

Coincidencias con una referencia propuesta de 16 códigos; su validación y la secuenciación siguen pendientes de revisión por un codificador.

Tarea 5. Metformina: explicación errónea del 8B

Encargo: detectar incoherencias, citar el informe y explicar la regla aplicada.

El informe dice que se suspendió la metformina por deterioro renal y que se reintroduce al alta.

Salida del 8B

```
"elemento": "Metformina",  
"tipo":  
  "farmaco_ineficaz_según_antibiograma",  
"conocimiento_aplicado": "ninguno"
```

Qué acierta y qué falla

Señala la metformina y propone suspenderla. La clasifica como un problema de antibiograma y no explicita el umbral de función renal.

El 8B detecta la metformina, pero la justifica con el antibiograma. Detectar el fármaco y explicar el riesgo son aciertos distintos.

Tarea 5. Qué incoherencias señala cada modelo

Problema planteado	Información necesaria	3B	8B	27B	Opus 5
Amoxicilina y alergia documentada	Principalmente el texto	sí	sí	sí	sí
Metformina y deterioro renal	Texto y regla clínica	no	sí*	sí	sí
Apixabán y criterios de reducción	Datos del caso y regla externa	no	no	sí	sí
Problemas señalados		1/3	2/3	3/3	3/3

*El 8B señala la metformina, con una clasificación errónea. 27B y Opus explicitan las reglas de función renal y reducción de apixabán.

Fuente: resultados/05-razonamiento-clinico__*.json y patrón de las tres incoherencias plantadas.

Tarea 5. El 27B propone una corrección incorrecta

El 27B señala las tres trampas y emite seis hallazgos. Uno de los adicionales propone reducir una dosis correcta.

Informe original

Tiotropio/olodaterol
2,5/2,5 mcg,
2 inhalaciones al día.

Propuesta del 27B

«Cambiar a **1 inhalación** una vez al día.»

La ficha técnica de Spiolto Respimat indica dos pulsaciones una vez al día. La corrección del 27B reduce indebidamente la dosis indicada.

Opus emite cinco hallazgos y no propone este cambio. Sus cinco entradas también necesitan revisión individual.

Fuente: salidas originales y AEMPS, ficha técnica de Spiolto Respimat, apartado 4.2.

El mismo antibiótico a través de las cinco tareas

Tarea	3B	8B	27B	Opus 5
1. Anonimización	conserva	conserva	conserva	conserva
2. Extracción	conserva	conserva	conserva	conserva
3. Reescritura	advierde	omite	conserva	advierde
4. Codificación*	—	—	—	—
5. Revisión clínica	señala	señala	señala	señala

El 27B conserva la prescripción al transformar el documento y la cuestiona cuando se le pide revisión clínica.

Fuente: salidas originales. *El encargo de codificación trata de diagnósticos; no evalúa la prescripción.

Comparación de los cuatro modelos en este caso

Resultado	3B	8B	27B	Opus 5
Identificadores del inventario eliminados	30/46	33/46	46/46	46/46
Pares medicamento–dosis coincidentes*	8/9	9/9	9/9	9/9
Antibiótico en la reescritura	advierde	omite	conserva	advierde
Códigos del patrón recuperados	1/16	2/16	5/16	15/16
Problemas clínicos señalados	1/3	2/3	3/3	3/3

Extracción: el 8B alcanza 9/9. Anonimización: el 27B alcanza 46/46. Codificación: el salto de 27B a Opus es de 5/16 a 15/16.

Fuente: salidas originales. *Nombres normalizados. Detección y coincidencia con el patrón no equivalen a una validación completa.

¿Cuánto tarda cada modelo en reescribir el alta?

9,4 s

3B · 303 palabras

27 s

8B · 386 palabras

30,8 min

27B · 624 palabras

27B: 37.995 de 39.401 tokens son razonamiento previo, el 96 %.

La espera incluye todo ese texto intermedio, aunque el paciente reciba solo 624 palabras. Reducir el razonamiento puede acortar el tiempo, pero exige volver a medir la calidad.

Fuente: resultados/o3-reescritura__*.meta.json. Palabras según el contador del evaluador. Sin tiempo comparable para Opus.

¿Por qué pueden tardar tanto?

Configuración local	3B	8B	27B
Archivo del modelo	2,4 GB	5,0 GB	30 GB
Tiempo total de las cinco tareas	1,3 min	4,1 min	101,7 min
Tokens registrados como razonamiento	0 %	52 %	93 %

Velocidad de generación

Hay que leer los valores del modelo desde memoria. Un modelo mayor mueve más datos por cada fragmento generado.

Longitud total generada

Cuenta tanto la respuesta como el razonamiento previo. En el 27B, este último suma 122.430 de 131.035 tokens.

Tiempo de generación = cantidad de tokens / tokens por segundo. Tamaño, equipo y razonamiento intervienen en la espera.

QUÉ SE PIERDE Y QUÉ SE GANA

Razonar y conocer son capacidades distintas

Razonar con los datos del informe

Anonimizar exige interpretar el contexto y aplicar reglas. **27B y Opus: 46/46** identificadores eliminados. 8B: 33/46.

En extracción, **8B, 27B y Opus: 9/9** pares medicamento-dosis.

El tamaño condiciona el equipo y la espera

Más parámetros y bits exigen **más disco y memoria**. El tiempo depende también del equipo y del razonamiento generado.

Cinco tareas en la demo: **8B, 5 GB y 4,1 min. 27B, 30 GB y 101,7 min.**

Añadir conocimientos clínicos

Codificar exige conocer la CIE: **27B recupera 5/16** códigos. **Opus, 15/16.**

Revisar exige además criterio clínico: el 27B detecta **3/3 trampas**, pero propone una corrección incorrecta.

QUÉ SE PIERDE Y QUÉ SE GANA

Control de los datos y forma de trabajo

Protección de datos y responsabilidad ética

Procesar en local es una de las vías más efectivas para simplificar el cumplimiento normativo: **los datos permanecen en la organización.**

Contratos que ejecuta el software

El usuario no conversa con el modelo. Se usa un contrato: se definen problema, reglas y formato exacto de respuesta. El software lo aplica, llama al modelo y procesa la salida.

Servidor compartido y resultados diferidos

Equipar a cada usuario resulta costoso. Debe planificarse el trabajo para que **un servidor centralice las solicitudes.** El resultado puede llegar horas después.

Informes y salidas de la demostración

Repositorio público

- `informes/`: el informe de alta sintético
- `resultados/`: los textos y JSON de los cuatro modelos
- `prompts/`: las instrucciones de cada tarea

Las salidas se identifican por tarea y modelo: 01 a 05, con las etiquetas 3B, 8B, 27B y Opus5.



[github.com/lucianosanchez/
demoSLM-IASalud](https://github.com/lucianosanchez/demoSLM-IASalud)

Los informes usados y las respuestas de todos los modelos empleados en esta demostración ya están precalculados y pueden consultarse desde el QR. Todos los informes son ficticios.