

Modelos de lenguaje pequeños en local: qué se pierde y qué se gana

Luciano Sánchez

Procesar informes clínicos con modelos locales permite utilizar IA sin enviar los datos a un proveedor externo. Es una vía especialmente eficaz para simplificar el cumplimiento normativo.

La demostración enfrenta tres modelos locales (de 3.000, 8.000 y 27.000 millones de parámetros) y a Claude Opus 5 con un mismo informe de alta sintético con tres trampas clínicas. Se evalúan cinco tareas: anonimización, extracción de datos, reescritura para el paciente, codificación CIE-10-ES y revisión del tratamiento.

El modelo local de 8.000 millones de parámetros anonimiza y extrae datos con la misma calidad que los modelos más potentes. El de 27.000 millones realiza correctamente todas las tareas que requieren razonar (en algún caso con mejor resultado que Claude) y detecta las tres trampas, pero propone una corrección discutible. Por otra parte, las tareas que requieren conocimientos, como son la codificación CIE y la revisión del tratamiento, no se resuelven de forma correcta por ninguno de los modelos, aunque los más potentes están más cerca de conseguirlo. Los modelos externos tienden a ser menos fieles con las instrucciones y en algunas ocasiones añaden cambios no solicitados.

También cambia el coste de obtener la respuesta: los modelos de 8.000 y 27.000 millones ocupan 5 y 30 GB y completan las cinco tareas en 4,1 y 101,7 minutos, respectivamente. El tamaño, la precisión, el equipo y el razonamiento generado condicionan la espera.

Para incorporar estas tareas al trabajo diario, los modelos locales no se usan de forma interactiva. Un servidor compartido permite concentrar recursos, pero a costa de que los resultados se retrasen, lo que requiere planificar el envío y la revisión de tareas.